

概率论与数理统计笔记

ixtWuko

主要包括：

- 随机事件，概率，条件概率，全概率公式、贝叶斯公式
- 古典概型、伯努利概型
- 随机变量
- 离散型随机变量的分布函数，0-1分布、二项分布、泊松分布、几何分布、超几何分布
- 连续型随机变量的分布函数，均匀分布、指数分布、正态分布
- （随机变量的函数）的分布
- 二维随机变量及其分布，二维均匀分布，二维正态分布
- （两个随机变量的函数）的分布
- 数学期望，方差，协方差，相关系数
- 大数定律和中心极限定理
- 样本数字特征
- 统计抽样分布： χ^2 分布， t 分布， F 分布
- 一个正态总体的抽样分布，两个正态总体的抽样分布
- 参数估计，点估计法（矩估计法、最大似然估计法），区间估计，正态总体的区间估计
- 假设检验的步骤，正态总体的假设检验

$$A_n^m = \frac{n!}{(n-m)!}, C_n^m = \frac{n!}{m!(n-m)!}.$$

一 随机事件与概率

1 基本概念

- 随机试验：可重复、所有可能结果或结果所在范围已知
- 样本空间 Ω 、样本点 ω
- 随机事件：样本空间的子集。必然事件 Ω 、不可能事件 \emptyset 。
- 事件的包含 \subset 、 \supset 、相等 $=$ 、交 \cap 、并 \cup 、差 $-$
- 互斥事件 $AB = \emptyset$ 、对立事件 $\overline{A} = \Omega - A$
- 运算规律

- 若 $A \subset B$, 则 $A \cup B = B, A \cap B = A$
- $A \cup B = B \cup A, A \cap B = B \cap A$
- $A \cup (B \cap C) = (A \cup B) \cap C,$
 $A \cap (B \cup C) = (A \cap B) \cup (A \cap C),$
 $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$
- $\overline{A \cup B} = \overline{A} \cap \overline{B},$
 $\overline{A \cap B} = \overline{A} \cup \overline{B}$
- $\bigcup_{i=1}^n A_i = \bigcap_{i=1}^n \overline{A_i},$
 $\overline{\bigcap_{i=1}^n A_i} = \bigcup_{i=1}^n \overline{A_i}$

- 频数、频率、概率

2 概率

定义

若实值函数 P 满足

- 对于任意事件 $P(A) \geq 0$,
- 对于必然事件 $P(\Omega) = 1$,
- 对于两两互斥的可数无穷多个事件有

$$P(A_1 \cup A_2 \cup \cdots \cup A_n \cup \cdots) = P(A_1) + P(A_2) + \cdots + P(A_n) + \cdots$$

则称 $P(\cdot)$ 为概率。

性质

- $P(\emptyset) = 0$
- $0 \leq P(A) \leq 1$
- $P(\overline{A}) = 1 - P(A)$
- 对于两两互斥的有限个事件有 $P(A_1 \cup A_2 \cup \cdots \cup A_n) = P(A_1) + P(A_2) + \cdots + P(A_n)$
- $A \subset B \implies P(A) \leq P(B), P(B - A) = P(B) - P(A)$
- 注意: $P(A) = 0$ 并不能得出 A 为不可能事件, $P(B) = 1$ 并不能得出 B 为必然事件; 例如几何概型这样样本具有连续性的, 有无穷个样本点, 取到某个点的概论是0, 取不到某个点的概率是1。

条件概率

$$P(B | A) = \frac{P(AB)}{P(A)}$$

为在事件 A 发生的条件下事件 B 发生的条件概率。

事件的独立性

设 A, B 两事件满足 $P(AB) = P(A)P(B)$, 则称 A, B 两事件独立。注意: 多个事件独立并不是简单的满足上式,

需要这些事件的全部任意组合都满足上式才行。如 A, B, C 相互独立需满足

$$\begin{cases} P(AB) = P(A)P(B) \\ P(BC) = P(B)P(C) \\ P(AC) = P(A)P(C) \\ P(ABC) = P(A)P(B)P(C) \end{cases}$$

- A, B 相互独立、 A, \bar{B} 相互独立、 \bar{A}, B 相互独立、 \bar{A}, \bar{B} 相互独立这四个结论之间等价。
- A, B 相互独立 $\iff P(B | A) = P(B) \iff P(B | \bar{A}) = P(B)$
- 当多个事件相互独立时, 它的部分也相互独立。

常用公式

- 加法公式: $P(A \cup B) = P(A) + P(B) - P(AB)$
- 减法公式: $P(A - B) = P(A) - P(AB) = P(A\bar{B})$
- 乘法公式: $P(AB) = P(B | A)P(A)$,
 $P(A_1 A_2 \cdots A_n) = P(A_1)P(A_2 | A_1) \cdots P(A_n | A_1 A_2 \cdots A_{n-1})$
- 全概率公式: 设 B_1, B_2, \cdots, B_n 满足 $\bigcup_{i=1}^n B_i = \Omega, B_i B_j = \emptyset (i \neq j)$ 且 $P(B_k) > 0, k = 1, 2, \cdots, n$, 则对任意事件 A 有 $P(A) = \sum_{i=1}^n P(B_i)P(A | B_i)$ 。

当 $n = 2$ 时, 全概率公式为 $P(A) = P(A | B)P(B) + P(A | \bar{B})P(\bar{B})$

- 贝叶斯公式: 设 B_1, B_2, \cdots, B_n 满足 $\bigcup_{i=1}^n B_i = \Omega, B_i B_j = \emptyset (i \neq j)$ 且 $P(A) > 0, P(B_k) > 0, k = 1, 2, \cdots, n$, 则 $P(B_j | A) = \frac{P(B_j)P(A | B_j)}{\sum_{i=1}^n P(B_i)P(A | B_i)}$ 。

(贝叶斯公式表征的是在已知一个结果的情况下, 对题设条件的推断。)

3 古典概型和伯努利概型

古典概型

包含有限个样本点, 且每个样本点发生的概率相同。

$$P(A) = \frac{n_A}{n}$$

几何概型

样本区间可以表示为一个几何区域, 且每个样本点发生的概率相同。

$$P(A) = \frac{L(\Omega_A)}{L(\Omega)} = \frac{\text{the area of } \Omega_A}{\text{the area of } \Omega}, \text{ 几何度量如长度、面积、体积等。}$$

n 重伯努利概型

各次实验是相互独立的，且每次实验只有两种结果中的一种。

设 $P(A) = p$ ，则在 n 重伯努利试验中事件 A 发生 k 次的概率为 $C_n^k p^k (1-p)^{n-k}, k = 1, 2, \dots, n$ 。

二 随机变量及其分布

1 随机变量及其分布函数

定义

- 随机变量：在样本空间上的实值函数 $X = X(\omega)$ 。
- 分布函数：记函数 $F(x) = P\{X \leq x\}$ 为随机变量 X 的分布函数。

分布函数的性质

- $0 \leq F(x) \leq 1$
- $F(-\infty) = 0, F(+\infty) = 1$
- $x_1 < x_2 \implies F(x_1) \leq F(x_2)$
- $F(x)$ 是右连续的，即 $F(x+0) = F(x)$
- 对任意 $x_1 < x_2$ ，有 $P\{x_1 < X \leq x_2\} = F(x_2) - F(x_1)$
- 对任意 x ，有 $P\{X = x\} = F(x) - F(x-0)$
- 只有满足以上条件的才能成为一个分布函数。
- $P\{X \leq x\} = F(x), P\{X < x\} = F(x-0)$

2 离散型随机变量、连续型随机变量

离散型

设离散型随机变量 X 的可能取值为 $x_1, x_2, \dots, x_n, \dots$ ， X 取各可能值的概率为 $P\{X = x_k\} = p_k, k = 1, 2, \dots$ ，被称为离散型随机变量的概率分布或分布律。

分布律也可以表格的形式给出

X	x_1	x_2	\dots	x_n	\dots
P	p_1	p_2	\dots	p_n	\dots

- $p_k \geq 0, k = 1, 2, \dots$
- $\sum_{i=1}^{+\infty} p_k = 1$

常用离散分布

- $(0-1)$ 分布：

X	0	1
P	$1-p$	p

- 伯努利分布/二项分布 $X \sim B(n, p)$: $P\{X = k\} = C_n^k p^k (1-p)^{n-k}, k = 0, 1, 2, \dots, n$

- 泊松分布 $X \sim P(\lambda)$: $P\{X = k\} = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, 2, \dots$

◦ 泊松定理: 在伯努利实验中, p_n 表示事件 A 在试验中出现的概率, 它与试验总数 n 有关, 如果

$$\lim_{n \rightarrow \infty} np_n = \lambda, \text{ 则 } \lim_{n \rightarrow \infty} C_n^k p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k}{k!} e^{-\lambda}$$

- 几何分布 $X \sim Ge(p)$: $P\{X = k\} = p(1 - p)^{k-1}, k = 1, 2, \dots$

- 超几何分布 $X \sim H(N, M, n)$: $P\{X = k\} = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}, k = l_1, \dots, l_2$, 其中

$l_1 = \max(0, n - N + M), l_2 = \min(M, n)$ 。如果 N 件产品中包含 M 件次品, 从中任取一次取出 n 件, 令 X 等于抽取的 n 件产品中的次品数, 则 X 服从超几何分布。

连续型

若对于分布函数 $F(x)$, 存在一个非负可积函数 $f(x)$, 使得对任意实数 x 都有

$$F(x) = \int_{-\infty}^x f(t) dt, -\infty < x < +\infty, \text{ 称函数 } f(x) \text{ 为连续型随机变量 } X \text{ 的概率密度。}$$

- $f(x) > 0$
- $\int_{-\infty}^{+\infty} f(x) dx = 1$
- 对任意实数 $x_1 < x_2$, 有

$$\begin{aligned} P\{x_1 < X < x_2\} &= P\{x_1 < X \leq x_2\} = P\{x_1 \leq X < x_2\} = P\{x_1 \leq X \leq x_2\} \\ &= \int_{x_1}^{x_2} f(t) dt = F(x_2) - F(x_1) \end{aligned}$$

- 在 $f(x)$ 的连续点处有 $F'(x) = f(x)$

常用连续分布

- 均匀分布 $X \sim U(a, b)$: 概率密度为 $f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{others} \end{cases}$
 - 对于 $a \leq c < d \leq b$, 有 $P\{c < X \leq d\} = \frac{d-c}{b-a}$
- 指数分布 $X \sim E(\lambda)$: 概率密度为 $f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$, 分布函数为 $F(x) = \begin{cases} 1 - e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$
- 正态分布 $X \sim N(\mu, \sigma^2)$: 概率密度为 $f(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < +\infty$ 。
 - 当 $X \sim N(0, 1)$ 时, 分布函数为 $\Phi = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$ 。
 - 当 $X \sim N(\mu, \sigma^2)$ 时, 分布函数为 $F(x) = \Phi(\frac{x-\mu}{\sigma})$ 。
 - $P\{a < X < b\} = \Phi(\frac{b-\mu}{\sigma}) - \Phi(\frac{a-\mu}{\sigma}), a < b$ 。
 - 概率密度 $f(x)$ 关于 $x = \mu$ 对称。

- $\Phi(-x) = 1 - \Phi(x)$
- $\Phi(0) = \frac{1}{2}$ 。
- $P\{|X| \leq a\} = 2\Phi(a) - 1$

- 补充：根据正态分布的概率密度，可以计算形如 $\int_{-\infty}^{+\infty} e^{-t^2} dx$ 的积分

3 随机变量的函数的分布

离散型

设 X 的分布律为 $P\{X = x_k\} = p_k, k = 1, 2, \dots$ ，则 X 的函数 $Y = g(X)$ 的分布律为

$P\{Y = g(x_k)\} = p_k, k = 1, 2, \dots$ 。如果在 $g(x_k)$ 中有相同的数值，则将它们相应的概率和作为 Y 取该值的概率。

连续型

- 公式法：设 X 的概率密度为 $f_X(x)$ ，又 $y = g(x)$ 是单调、导数不为零的可导函数， $h(y)$ 是它的反函数，则 X 的函数 $Y = g(X)$ 的概率密度为

$$f_Y(y) = \begin{cases} |h'(x)|f_X(h(y)), & \alpha < y < \beta \\ 0, & \text{others} \end{cases}。$$

- 定义法： $F_Y(y) = P\{Y \leq y\} = P\{g(X) \leq y\} = \int_{g(x) \leq y} f_X(x) dx。$
 $f_Y(y) = F'_Y(y)$

三 多维随机变量及其分布

1 二维随机变量及其分布

二维随机变量

- 二维随机变量的联合分布函数 $F(x, y) = P\{X \leq x, Y \leq y\}, -\infty < x < +\infty, -\infty < y < +\infty$
- $F(x, y)$ 的性质
 - $0 \leq F(x, y) \leq 1$
 - $F(-\infty, y) = F(x, -\infty) = F(-\infty, -\infty) = 0$
 - $F(+\infty, +\infty) = 1$
 - $F(x, y)$ 对于 x, y 均单调不减。
 - $F(x, y)$ 对于 x, y 均右连续。
 - $P\{a < x \leq b, c < y \leq d\} = F(b, d) - F(b, c) - F(a, d) + F(a, c)$
- 二维随机变量的边缘分布
 - $F_X(x) = P\{X \leq x\} = F(x, +\infty)$

- $F_Y(y) = P\{Y \leq y\} = F(+\infty, y)$
- 二维随机变量的条件分布
 - $F_{X|Y}(x|y) = P\{X \leq x|Y = y\}$

$$= \lim_{\varepsilon \rightarrow 0^+} P\{X \leq x|y - \varepsilon < Y \leq y + \varepsilon\}$$

$$= \lim_{\varepsilon \rightarrow 0^+} \frac{P\{X \leq x, y - \varepsilon < Y \leq y + \varepsilon\}}{P\{y - \varepsilon < Y \leq y + \varepsilon\}}$$
 - 同理可以定义 $F_{Y|X}(y|x)$

二维离散型随机变量

- 二维离散型随机变量的概率分布（分布律） $P\{X = x_i, Y = y_j\} = p_{ij}, i, j = 1, 2, 3, \dots$
- 二维离散型随机变量的联合分布函数 $F(x, y) = \sum_{x_i \leq x} \sum_{y_j \leq y} p_{ij}$
- 二维离散型随机变量的边缘分布
 - $p_{i\cdot} = P\{X = x_i\} = \sum_{j=1}^{+\infty} p_{ij}$
 - $p_{\cdot j} = P\{Y = y_j\} = \sum_{i=1}^{+\infty} p_{ij}$
- 二维离散型随机变量的条件分布
 - $P\{X = x_i|Y = y_j\} = \frac{P\{X = x_i, Y = y_j\}}{P\{Y = y_j\}} = \frac{p_{ij}}{p_{\cdot j}}$
 - $P\{Y = y_j|X = x_i\} = \frac{P\{X = x_i, Y = y_j\}}{P\{X = x_i\}} = \frac{p_{ij}}{p_{i\cdot}}$
- p_{ij} 的性质
 - $p_{ij} \geq 0$
 - $\sum_i \sum_j p_{ij} = 1$

二维连续型随机变量

- 二维连续型随机变量的概率密度 $f(x, y)$
- 二维连续型随机变量的联合分布函数 $F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$
- 二维连续型随机变量的边缘密度
 - $f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$
 - $f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$
- 二维连续型随机变量的条件密度

$$\begin{aligned} \circ f_{X|Y}(x|y) &= \frac{f(x,y)}{f_Y(y)}, F_{X|Y}(x|y) = \int_{-\infty}^x \frac{f(s,y)}{f_Y(y)} ds \\ \circ f_{Y|X}(y|x) &= \frac{f(x,y)}{f_X(x)}, F_{Y|X}(y|x) = \int_{-\infty}^y \frac{f(x,s)}{f_X(x)} ds \end{aligned}$$

- $f(x,y)$ 的性质
 - $f(x,y) \geq 0$
 - $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x,y) dx dy = 1$

2 随机变量的独立性

随机变量的独立性

如果对于任意 x, y 都有 $P\{X \leq x, Y \leq y\} = P\{X \leq x\}P\{Y \leq y\}$ 即 $F(x,y) = F_X(x)F_Y(y)$, 则称随机变量 X 和 Y 相互独立。

随机变量相互独立的充分必要条件

- 离散型随机变量相互独立 $\iff p_{ij} = p_i \cdot p_j$
- 连续型随机变量相互独立 $\iff f(x,y) = f_X(x)f_Y(y)$

3 二维均匀分布和二维正态分布

二维均匀分布

$$f(x,y) = \begin{cases} \frac{1}{A} & (x,y) \in G \\ 0 & \text{others} \end{cases}$$

- 均匀分布与几何度量密不可分。

二维正态分布

$$(X,Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$$

$$f(x,y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\}$$

$$\text{其中, } \rho = \frac{\text{cov}(X,Y)}{\sqrt{D_X}\sqrt{D_Y}}$$

- 若 $(X,Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$, 则 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$ 。
- 概率论中约定: 相互独立的正态随机变量 X 和 Y 就是指 $(X,Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; 0)$ 。
- X 和 Y 相互独立 $\iff \rho = 0$
- 当行列式 $\begin{vmatrix} a & b \\ c & d \end{vmatrix} \neq 0$ 时, $(aX+bY, cX+dY)$ 也一定是二维正态分布。
- (X,Y) 为二维正态分布, 且 $a^2+b^2 \neq 0$, 则 $aX+bY \sim N(a\mu_1+b\mu_2, a^2\sigma_1^2+2ab\sigma_1\sigma_2\rho+b^2\sigma_2^2)$ 。

- X_1, X_2, \dots, X_n 相互独立, 且 $X_i \sim N(\mu_i, \sigma_i^2)$, 则 $\sum_{i=1}^n C_i X_i \sim N(\sum_{i=1}^n C_i \mu_i, \sum_{i=1}^n C_i^2 \sigma_i^2)$.

4 两个随机变量函数的分布

离散型

对于 $Z = g(X, Y)$, 有 $P\{Z = z_k\} = P\{g(X, Y) = z_k\} = \sum_{g(x_i, y_j) = z_k} p_{ij}$. 也即可以取到相同 Z 值的 (x, y) 的概率累加。

连续型

对于 $Z = g(X, Y)$, 有 $F_Z(z) = P\{Z \leq z\} = P\{g(X, Y) \leq z\} = \iint_{g(x, y) \leq z} f(x, y) dx dy$.

有以下几种常见情况:

- $Z = X \pm Y$ 、 $Z = XY$ 、 $Z = \frac{X}{Y}$, 以 Z 表示 Y , 根据 X, Y 的范围确定 Z 的范围, 然后分区域进行积分

$$F_Z(z) = \int_{-\infty}^{+\infty} f(x, y(z)) |y'(z)| dx.$$

特别的, 当 $Z = X + Y$ 时,

$$F_Z(z) = \int_{-\infty}^{+\infty} dx \int_{-\infty}^{z-x} f(x, y) dy$$

$$f_Z(z) = \int_{-\infty}^{+\infty} f(x, z-x) dx = \int_{-\infty}^{+\infty} f(z-y, y) dy$$

当 X, Y 相互独立时, $f(x, y) = f_X(x) f_Y(y)$, 则

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx = \int_{-\infty}^{+\infty} f_X(z-y) f_Y(y) dy = f_X * f_Y, \text{ 被成为卷积公式.}$$

- $Z = \max(X, Y)$, 则 $F_Z(z) = P\{\max(X, Y) \leq z\} = P\{X \leq z, Y \leq z\} = F_{XY}(z, z)$
- $Z = \min(X, Y)$, 则 $F_Z(z) = P\{\min(X, Y) \leq z\} = P\{(X \leq z) \cup (Y \leq z)\}$
 $= F_X(z) + F_Y(z) - F_{XY}(z, z)$
- X, Y 相互独立, 则
 - $X \sim B(n, p), Y \sim B(m, p) \rightarrow X + Y \sim B(n + m, p)$
 - $X \sim P(\lambda_1), Y \sim P(\lambda_2) \rightarrow X + Y \sim P(\lambda_1 + \lambda_2)$

四 随机变量的数字特征

1 数学期望

数学期望的定义

- 离散型, $EX = \sum_{k=1}^{+\infty} x_k p_k$

- 连续型, $EX = \int_{-\infty}^{+\infty} xf(x)dx$

数学期望的性质

- $E(C) = C$
- $E(aX + b) = aEX + b$
- $E(X \pm Y) = EX \pm EY$
- X, Y 相互独立, 则 $E(XY) = EXEY$

随机变量函数的期望

对于 $Y = g(X)$,

- 离散型, $EY = E(g(X)) = \sum_{k=1}^{+\infty} g(x_k)p_k$
- 连续型, $EY = E(g(X)) = \int_{-\infty}^{+\infty} g(x)f(x)dx$

二维随机变量函数的期望

对于 $Z = g(X, Y)$,

- 离散型, $EZ = E(g(X, Y)) = \sum_{i=1}^{+\infty} \sum_{j=1}^{+\infty} g(x_i, y_j)p_{ij}$
- 连续型, $EZ = E(g(X, Y)) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y)f(x, y)dxdy$

2 方差

方差的定义

方差 $DX = E\{[X - E(X)]^2\}$ 。

标准差或均方差 $\sigma(X) = \sqrt{DX}$ 。

方差的计算

$$DX = E(X^2) - (EX)^2$$

方差的性质

- $D(C) = 0$
- $D(aX + b) = a^2 DX$
- $D(X \pm Y) = DX + DY \pm 2\text{cov}(X, Y)$
- 若 X, Y 相互独立, 则 $D(aX + bY) = a^2 DX + b^2 DY$,
 $D(XY) = DX \cdot DY + DX(EY)^2 + DY(EX)^2$

3 常用随机变量的数学期望和方差

- 0-1分布, $EX = p, DX = p(1 - p)$
- 二项分布 $X \sim B(n, p)$, $EX = np, DX = np(1 - p)$
- 泊松分布 $X \sim P(\lambda)$, $EX = \lambda, DX = \lambda$
- 几何分布 $X \sim Ge(p)$, $EX = \frac{1}{p}, DX = \frac{1-p}{p^2}$
- 超几何分布 $X \sim H(N, M, n)$, $EX = n\frac{M}{N}, DX = \frac{nM(N-M)(N-n)}{N^2(N-1)}$
- 均匀分布 $X \sim U(a, b)$, $E(X) = \frac{a+b}{2}, D(X) = \frac{(b-a)^2}{12}$
- 指数分布 $X \sim E(\lambda)$, $E(X) = \frac{1}{\lambda}, D(X) = \frac{1}{\lambda^2}$
- 正态分布 $X \sim N(\mu, \sigma^2)$, $E(X) = \mu, D(X) = \sigma^2$
- $\chi^2(n)$ 分布, $EX = n, DX = 2n$

4 矩

矩的定义

- k 阶原点矩: $E(x^k)$
- k 阶中心矩: $E[(X - EX)^k]$
- X, Y 的 $k + l$ 阶混合矩 $E(X^k Y^l)$
- X, Y 的 $k + l$ 阶混合中心矩 $E[(X - EX)^k (Y - EY)^l]$

5 协方差

协方差的定义

- 协方差 $\text{cov}(X, Y) = E[(X - EX)(Y - EY)] = E(XY) - EXEY$
- 协方差矩阵

$$C = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{pmatrix}, \text{ 其中 } c_{ij} = \text{cov}(X_i, X_j), c_{ij} = c_{ji}.$$

协方差的性质

- $\text{cov}(X, Y) = E(XY) - EXEY$
- $D(X \pm Y) = DX + DY \pm 2\text{cov}(X, Y)$
- $\text{cov}(X, Y) = \text{cov}(Y, X)$
- $\text{cov}(X, X) = DX$
- $\text{cov}(X, C) = 0$
- $\text{cov}(aX, bY) = ab\text{cov}(X, Y)$
- $\text{cov}(X_1 + X_2, Y) = \text{cov}(X_1, Y) + \text{cov}(X_2, Y)$

6 相关系数

相关系数的定义

$$\text{相关系数 } \rho_{XY} = \frac{\text{cov}(X, Y)}{\sqrt{DX}\sqrt{DY}}$$

相关系数的性质

- $|\rho_{XY}| \leq 1$
- $|\rho_{XY}| = 1 \iff$ 存在不全为零的常数 a, b 使得 $P\{aX + bY = 1\} = 1$
- 若 $\rho_{XY} = 0$, 则 X, Y 不相关。
- $\rho_{XX} = 1$
- 若随机变量 X, Y 相互独立, 则 X, Y 必不相关。反之不成立。
- 对于二维正态随机变量, 相互独立和不相关是等价的。

五 大数定律和中心极限定理

1 切比雪夫不等式

设随机变量 X 的数学期望 $E(X)$ 和方差 $D(X)$ 存在, 则对任何的 $\varepsilon > 0$, 总有 $P\{|X - E(X)| \geq \varepsilon\} \leq \frac{D(X)}{\varepsilon^2}$

2 依概率收敛

设 $X_1, X_2, \dots, X_n, \dots$ 是一个随机变量序列, A 是一个常数, 如果对任意 $\varepsilon > 0$, 有

$\lim_{n \rightarrow +\infty} P\{|X_n - A| < \varepsilon\} = 1$, 则称随机变量序列 $X_1, X_2, \dots, X_n, \dots$ 依概率收敛于 A 。

3 切比雪夫大数定律

设 $X_1, X_2, \dots, X_n, \dots$ 为相互独立的随机变量序列, 存在常数 C , 使 $D(X_i) \leq C (i = 1, 2, \dots)$, 则对任意 $\varepsilon > 0$

$$, \text{ 有 } \lim_{n \rightarrow +\infty} P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \varepsilon\right\} = 1$$

4 辛钦大数定律

设随机变量 $X_1, X_2, \dots, X_n, \dots$ 独立同分布, 具有数学期望 $E(X_i) = \mu, i = 1, 2, \dots$, 则对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow +\infty} P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| < \varepsilon\right\} = 1$$

5 伯努利大数定律

设随机变量 $X_n \sim B(n, p), n = 1, 2, \dots$, 则对于任意 $\varepsilon > 0$, 有 $\lim_{n \rightarrow +\infty} P\left\{\left|\frac{X_n}{n} - p\right| < \varepsilon\right\} = 1$

6 列维-林德伯格中心极限定理

设随机变量 $X_1, X_2, \dots, X_n, \dots$ 独立同分布, $E(X_n) = \mu, D(X_n) = \sigma^2, n = 1, 2, \dots$, 则对任意实数 x , 有

$$\lim_{n \rightarrow +\infty} P \left\{ \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq x \right\} = \Phi(x) \text{ 表明当 } n \text{ 充分大时, } \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \sim N(0, 1).$$

7 棣莫弗-拉普拉斯中心极限定理

设随机变量 $X_n \sim B(n, p), n = 1, 2, \dots$, 则对任意实数 x , 有 $\lim_{n \rightarrow +\infty} P \left\{ \frac{X_n - np}{\sqrt{np(1-p)}} \leq x \right\} = \Phi(x)$ 表明当 n

充分大时, $\frac{X_n - np}{\sqrt{np(1-p)}} \sim N(0, 1)$ 。

8 李雅普诺夫中心极限定理

设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立, $E(X_i) = \mu_i, D(X_i) = \sigma_i^2, i = 1, 2, \dots$ 。记 $B_n^2 = \sum_{i=1}^n \sigma_i^2$, 若存在

正数 δ , 使得 $\lim_{n \rightarrow +\infty} \frac{1}{B_n^{2+\delta}} \sum_{i=1}^n E(|X_i - \mu_i|^{2+\delta}) = 0$, 则有 $\lim_{n \rightarrow +\infty} P \left\{ \frac{\sum_{i=1}^n X_i - \sum_{i=1}^n \mu_i}{B_n} \leq x \right\} = \Phi(x)$ 表

明当 n 充分大时, $\frac{\sum_{i=1}^n X_i - \sum_{i=1}^n \mu_i}{B_n} \sim N(0, 1)$ 。

六 数理统计的基本概念

1 基本概念

概念: 总体、样本、统计量 (以样本作为输入, 经过一个不含其它未知量的函数, 所得的量)

样本数字特征

- 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
- 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
- 样本标准差 $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$
- 样本 k 阶原点矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, k = 1, 2, A_1 = \bar{X}$
- 样本 k 阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, k = 1, 2, B_2 = \frac{n-1}{n} S^2 \neq S^2$
- 顺序统计量 将样本 X_1, X_2, \dots, X_n 按从小到大的顺序排列, 第 k 个称为第 k 顺序统计量, 记作 $X_{(k)}$ 。
 $X_{(1)} = \min(X_1, X_2, \dots, X_n), X_{(n)} = \max(X_1, X_2, \dots, X_n)$

样本数字特征的性质

- 若总体 X 具有数学期望 $E(X) = \mu$, 则 $E(\bar{X}) = E(X) = \mu$
- 若总体 X 具有方差 $D(X) = \sigma^2$, 则 $D(\bar{X}) = \frac{1}{n}D(X) = \frac{\sigma^2}{n}$, $E(S^2) = D(X) = \sigma^2$
- 若总体 X 的 k 阶原点矩 $E(X^k) = \mu_k, k = 1, 2, \dots$ 存在, 则 $\lim_{n \rightarrow +\infty} \frac{1}{n} \sum_{i=1}^n X_i^k = \mu_k, k = 1, 2, \dots$

2 常用统计抽样分布和正态总体的抽样分布

χ^2 分布

- 定义: 设随机变量 X_1, X_2, \dots, X_n 相互独立且均服从标准正态分布 $N(0, 1)$, 则称随机变量 $\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2$ 服从自由度为 n 的 χ^2 分布, 记作 $\chi^2 \sim \chi^2(n)$ 。
- 性质:
 - 设 $\chi^2 \sim \chi^2(n)$, 则 $E(\chi^2) = n, D(\chi^2) = 2n$
 - 设 $\chi_1^2 \sim \chi^2(n_1), \chi_2^2 \sim \chi^2(n_2)$, 且 χ_1^2, χ_2^2 相互独立, 则 $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$
 - 设 $\chi^2 \sim \chi^2(n)$, 对给定的 $\alpha(0 < \alpha < 1)$, 称满足条件 $P\{\chi^2 > \chi_\alpha^2(n)\} = \int_{\chi_\alpha^2(n)}^{+\infty} f(x)dx = \alpha$ 的点 $\chi_\alpha^2(n)$ 为 $\chi^2(n)$ 分布的上 α 分位点。

t 分布

- 定义: 设随机变量 X, Y 相互独立, 且 $X \sim N(0, 1), Y \sim \chi^2(n)$, 则称随机变量 $T = \frac{X}{\sqrt{Y/n}}$ 服从自由度为 n 的 t 分布, 记作 $T \sim t(n)$ 。
- 性质:
 - t 分布的概率密度 $f(x)$ 是偶函数, 且当 n 充分大时, $t(n)$ 分布近似于 $N(0, 1)$ 分布。
 - 设 $T \sim t(n)$, 对给定的 $\alpha(0 < \alpha < 1)$, 称满足条件 $P\{T > t_\alpha(n)\} = \int_{t_\alpha(n)}^{+\infty} f(x)dx = \alpha$ 的点 $t_\alpha(n)$ 为 $t(n)$ 分布的上 α 分位点。
 - $t_{1-\alpha}(n) = -t_\alpha(n)$

F 分布

- 定义: 设随机变量 X, Y 相互独立, 且 $X \sim \chi^2(n_1), Y \sim \chi^2(n_2)$, 则称随机变量 $F = \frac{X/n_1}{Y/n_2}$ 服从自由度为 (n_1, n_2) 的 F 分布, 记作 $F \sim F(n_1, n_2)$, 其中 n_1 和 n_2 分别成为第一自由度和第二自由度。
- 性质:
 - 设 $F \sim F(n_1, n_2)$, 对给定的 $\alpha(0 < \alpha < 1)$, 称满足条件 $P\{F > F_\alpha(n_1, n_2)\} = \int_{F_\alpha(n_1, n_2)}^{+\infty} f(x)dx = \alpha$ 的点 $F_\alpha(n_1, n_2)$ 为 $F(n_1, n_2)$ 分布的上 α 分位点。

◦ 若 $F \sim F(n_1, n_2)$, 则 $\frac{1}{F} \sim F(n_2, n_1)$, 且有 $F_{1-\alpha}(n_1, n_2) = \frac{1}{F_\alpha(n_2, n_1)}$ 。

一个正态总体的抽样分布

设总体 $X \sim N(\mu, \sigma^2)$, X_1, X_2, \dots, X_n 是来自总体的样本, 样本均值为 \bar{X} , 样本方差为 S^2 , 则有:

• \bar{X} 和 S^2 相互独立

• (已知 σ 求 μ) $\bar{X} \sim N(\mu, \frac{\sigma^2}{n}) \rightarrow U = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$

• (未知 σ 求 μ) $U = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$, $\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$,

$$T = \frac{U}{\sqrt{\chi^2/(n-1)}} = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1), \text{ 另外 } F = \frac{U^2/1}{\chi^2/(n-1)} = \frac{n(\bar{X} - \mu)^2}{S^2} \sim F(1, n-1)$$

• (已知 μ 求 σ) $\frac{X_i - \mu}{\sigma} \sim N(0, 1) \rightarrow$

$$\chi^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n)$$

• (未知 μ 求 σ) $\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ 。(证明很麻烦)

两个正态总体的抽样分布

设总体 $X \sim N(\mu_1, \sigma_1^2)$ 和总体 $Y \sim N(\mu_2, \sigma_2^2)$, X_1, X_2, \dots, X_n 和 Y_1, Y_2, \dots, Y_n 是分别来自总体 X 和 Y 的样本且相互独立, 样本均值分别为 \bar{X} 和 \bar{Y} , 样本方差为 S_1^2 和 S_2^2 , 则有:

• $\bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right)$

$$U = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$$

• 若 $\sigma_1^2 = \sigma_2^2$, 则 $T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$, 其中 $S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$

• $F = \frac{\frac{1}{n_1 \sigma_1^2} \sum_{i=1}^{n_1} (X_i - \mu_1)^2}{\frac{1}{n_2 \sigma_2^2} \sum_{i=1}^{n_2} (Y_i - \mu_2)^2} \sim F(n_1, n_2)$

• $F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$

七 参数估计

1 点估计

设总体 X 的分布函数为 $F(x; \theta)$, θ 是待估参数, X_1, X_2, \dots, X_n 是总体 X 的一个样本, 构造一个适当的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 来估计 θ 的问题称为参数的点估计问题。统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 称为 θ 的估计量。

构造估计量的方法

- 矩估计法: 用样本矩估计相应的总体矩, 用样本矩的函数估计总体矩相应的函数。

- 设 X 为连续型随机变量, 其概率密度为 $f(x; \theta_1, \theta_2, \dots, \theta_k)$, 其中 $\theta_1, \theta_2, \dots, \theta_k$ 为待估参数, 共 k 个, X_1, X_2, \dots, X_n 为来自 X 的样本。

假设总体 X 的前 k 阶矩为 $\mu_l = E(X^l) = \int_{-\infty}^{+\infty} x^l f(x; \theta_1, \theta_2, \dots, \theta_k) dx, l = 1, 2, \dots, k$ 。对应的样本矩为 $A_l = \frac{1}{n} \sum_{i=1}^n X_i^l, l = 1, 2, \dots, k$ 。样本矩依概率收敛于总体矩, $\mu_l = A_l, l = 1, 2, \dots, k$, 因此得到 k 个方程 (由于有 k 个待估参数) 组成的方程组, 解得 k 个待估参数。 (μ_l 根据随机变量的形式获得, A_l 根据样本值获得。)

- 设 X 为离散型随机变量, 其分布律为 $p(x; \theta_1, \theta_2, \dots, \theta_k)$, 其中 $\theta_1, \theta_2, \dots, \theta_k$ 为待估参数, 共 k 个, X_1, X_2, \dots, X_n 为来自 X 的样本。

假设总体 X 的前 k 阶矩为 $\mu_l = E(X^l) = \sum_{x \in R_X} x^l p(x; \theta_1, \theta_2, \dots, \theta_k), l = 1, 2, \dots, k$ 。对应的样本矩为 $A_l = \frac{1}{n} \sum_{i=1}^n X_i^l, l = 1, 2, \dots, k$ 。样本矩依概率收敛于总体矩, $\mu_l = A_l, l = 1, 2, \dots, k$, 因此得到 k 个方程 (由于有 k 个待估参数) 组成的方程组, 解得 k 个待估参数。 (μ_l 根据随机变量的形式获得, A_l 根据样本值获得。)

- 最大似然估计:

- 设总体 X 是离散型随机变量, 其分布律为 $p(x; \theta), \theta \in \Theta$, Θ 的形式已经给出, θ 为待估参数。 X_1, X_2, \dots, X_n 为来自 X 的样本。

又设 x_1, x_2, \dots, x_n 是相应于样本 X_1, X_2, \dots, X_n 的一个样本值, 取得这一样本值的概率为

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta)。L(\theta)称为样本的似然函数。$$

根据似然函数和 θ 的取值范围挑选**似然函数最大**的参数取值 $\hat{\theta}$, 称为参数 θ 的最大似然估计值。

- 设总体 X 是连续型随机变量, 其概率密度为 $f(x; \theta), \theta \in \Theta$, Θ 的形式已经给出, θ 为待估参数。 X_1, X_2, \dots, X_n 为来自 X 的样本。

又设 x_1, x_2, \dots, x_n 是相应于样本 X_1, X_2, \dots, X_n 的一个样本值, 取得这一样本值的概率为

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)。L(\theta)称为样本的似然函数。$$

根据似然函数和 θ 的取值范围挑选**似然函数最大**的参数取值 $\hat{\theta}$, 称为参数 θ 的最大似然估计值。

- 若 $L(\theta)$ 或者 $\ln L(\theta)$ 关于 θ 可微, 值 $\hat{\theta}$ 可以从方程 $\frac{dL(\theta)}{d\theta} = 0$ 或者 $\frac{d \ln L(\theta)}{d\theta} = 0$ 来求得。(求极值)

若要估计的参数有两个, 可以根据偏导数等于零求得。

估计量的评选标准

- 无偏性/无偏估计量 $E(\hat{\theta}) = \theta$, 参数的估计量就是参数的实际值。
- 有效性/更有效的估计量 $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$, 称估计量 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 更有效。
- 相合性/一致估计量 对于任意 $\varepsilon < 0$, 有 $\lim_{n \rightarrow \infty} P\{|\hat{\theta} - \theta| < \varepsilon\} = 1$ 。(使用大数定律来证明)

2 区间估计

置信区间

设 θ 是总体 X 的未知参数, X_1, X_2, \dots, X_n 是来自总体 X 的样本, 如果两个统计量

$\theta_1 = \theta_1(X_1, X_2, \dots, X_n), \theta_2 = \theta_2(X_1, X_2, \dots, X_n)$ 满足 $P\{\theta_1 < \theta < \theta_2\} = 1 - \alpha$ 则称随机区间 (θ_1, θ_2) 为参数 θ 的**置信水平**为 $1 - \alpha$ 的**置信区间** (或区间估计), θ_1, θ_2 分别称为置信下限和置信上限。

另外还有单侧置信限, 使用同样的方法计算。

正态总体的区间估计

其枢轴量分布的构造见上一节正态总体的抽样分布。

- 一个总体的参数的区间估计。设总体 $X \sim N(\mu, \sigma^2)$, X_1, X_2, \dots, X_n 是来自总体 X 的样本, \bar{X}, S^2 分别是样本均值和样本方差。

unknown parameter	$1 - \alpha$ confidence interval
μ (σ^2 known)	$\left(\bar{X} - u_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{X} + u_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right)$
μ (σ^2 unknown)	$\left(\bar{X} - t_{\frac{\alpha}{2}}(n-1) \frac{S}{\sqrt{n}}, \bar{X} + t_{\frac{\alpha}{2}}(n-1) \frac{S}{\sqrt{n}} \right)$
σ^2	$\left(\frac{(n-1)S^2}{\chi_{\frac{\alpha}{2}}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)} \right)$

- 两个总体的参数的区间估计。设总体 $X \sim N(\mu_1, \sigma_1^2)$ 和总体 $Y \sim N(\mu_2, \sigma_2^2)$, X_1, X_2, \dots, X_n 和 Y_1, Y_2, \dots, Y_n 是分别来自总体 X 和总体 Y 的样本, $\bar{X}, \bar{Y}, S_1^2, S_2^2$ 分别是样本均值和样本方差。

$$S_{\omega}^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

unknown parameter	$1 - \alpha$ confidence interval
$\mu_1 - \mu_2$ (σ_1^2, σ_2^2 known)	$\left(\bar{X} - \bar{Y} - u_{\frac{\alpha}{2}} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, \bar{X} - \bar{Y} + u_{\frac{\alpha}{2}} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right)$
$\mu_1 - \mu_2$ (σ_1^2, σ_2^2 unknown, but $\sigma_1^2 = \sigma_2^2$)	$\left(\bar{X} - \bar{Y} - t_{\frac{\alpha}{2}}(n_1 + n_2 - 2)S_{\omega} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, \bar{X} - \bar{Y} + t_{\frac{\alpha}{2}}(n_1 + n_2 - 2)S_{\omega} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right)$
$\frac{\sigma_1^2}{\sigma_2^2}$	$\left(\frac{S_1^2}{S_2^2} \cdot \frac{1}{F_{\frac{\alpha}{2}}(n_1 - 1, n_2 - 2)}, \frac{S_1^2}{S_2^2} \cdot F_{\frac{\alpha}{2}}(n_1 - 1, n_2 - 2) \right)$

八 假设检验

1 定义

假设检验

根据样本，按照一定的规则判断所做的假设真伪，并作出接受还是拒绝此假设的决定。

两类错误

对于假设 H_0 ,

- 第一类错误：拒绝实际真的假设。
- 第二类错误：接受实际不真的假设。

显著性

- 显著性水平：在假设检验中允许犯第一类错误的概率。记作 α ，它表现了对弃真程度的控制。即发生 H_0 为真而拒绝了 H_0 这种事件的概率。
- 显著性检验：只控制第一类错误的检验。

显著性检验的一般步骤

1. 根据问题提出原假设 H_0 ，（由此也可以得出对立的假设 H_1 ）；
2. 给出显著性水平 α ，可以取0.1, 0.05, 0.01, 0.001等；
3. 确定检验的统计量、拒绝域 W 形式；
4. 按照犯第一类错误的概率等于 α 求出拒绝域 W 的具体值；

5. 根据样本值计算检验统计量 T 的观测值 t , 若 $t \in W$, 则拒绝原假设 H_0 , 否则, 接受原假设 H_0 。

2 正态总体参数的假设检验

设显著性水平为 α , 单个正态总体为 $N(\mu, \sigma^2)$ 的参数的假设检验以及两个正态总体 $N(\mu_1, \sigma_1^2), N(\mu_2, \sigma_2^2)$ 的

$\mu_1 - \mu_2$ 和 $\sigma_1^2 = \sigma_2^2$ 的假设检验。表中 $S_\omega = \sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}}$

parameter test	H_0	H_1	static test	distribution of static when H_0 is true	reject region
μ (σ^2 known)	$\mu = \mu_0$ $\mu \leq \mu_0$ $\mu \geq \mu_0$	$\mu \neq \mu_0$ $\mu > \mu_0$ $\mu < \mu_0$	$U = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$N(0, 1)$	$ U \geq u_{\frac{\alpha}{2}}$ $U \geq u_\alpha$ $U \leq -u_\alpha$
μ (σ^2 unknown)	$\mu = \mu_0$ $\mu \leq \mu_0$ $\mu \geq \mu_0$	$\mu \neq \mu_0$ $\mu > \mu_0$ $\mu < \mu_0$	$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$	$t(n-1)$	$ T \geq t_{\frac{\alpha}{2}}(n-1)$ $T \geq t_\alpha(n-1)$ $T \leq -t_\alpha(n-1)$
σ^2 (μ known)	$\sigma^2 = \sigma_0^2$ $\sigma^2 \leq \sigma_0^2$ $\sigma^2 \geq \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$ $\sigma^2 > \sigma_0^2$ $\sigma^2 < \sigma_0^2$	$\chi^2 = \frac{1}{\sigma_0^2} \sum_{i=1}^n (X_i - \mu)^2$	$\chi^2(n)$	$\chi^2 \leq \chi_{1-\frac{\alpha}{2}}^2(n)$ or $\chi^2 \geq \chi_{\frac{\alpha}{2}}^2(n)$ $\chi^2 \geq \chi_\alpha^2(n)$ $\chi^2 \leq \chi_{1-\alpha}^2(n)$
σ^2 (μ unknown)	$\sigma^2 = \sigma_0^2$ $\sigma^2 \leq \sigma_0^2$ $\sigma^2 \geq \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$ $\sigma^2 > \sigma_0^2$ $\sigma^2 < \sigma_0^2$	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$	$\chi^2(n-1)$	$\chi^2 \leq \chi_{1-\frac{\alpha}{2}}^2(n-1)$ or $\chi^2 \geq \chi_{\frac{\alpha}{2}}^2(n-1)$ $\chi^2 \geq \chi_\alpha^2(n-1)$ $\chi^2 \leq \chi_{1-\alpha}^2(n-1)$
$\mu_1 - \mu_2$ (σ_1^2, σ_2^2 known)	$\mu_1 - \mu_2 = \mu_0$ $\mu_1 - \mu_2 \leq \mu_0$ $\mu_1 - \mu_2 \geq \mu_0$	$\mu_1 - \mu_2 \neq \mu_0$ $\mu_1 - \mu_2 > \mu_0$ $\mu_1 - \mu_2 < \mu_0$	$U = \frac{\bar{X} - \bar{Y} - \mu_0}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$	$N(0, 1)$	$ U \geq u_{\frac{\alpha}{2}}$ $U \geq u_\alpha$ $U \leq -u_\alpha$
$\mu_1 - \mu_2$ (σ_1^2, σ_2^2 unknown but $\sigma_1^2 = \sigma_2^2$)	$\mu_1 - \mu_2 = \mu_0$ $\mu_1 - \mu_2 \leq \mu_0$ $\mu_1 - \mu_2 \geq \mu_0$	$\mu_1 - \mu_2 \neq \mu_0$ $\mu_1 - \mu_2 > \mu_0$ $\mu_1 - \mu_2 < \mu_0$	$T = \frac{\bar{X} - \bar{Y} - \mu_0}{S_\omega \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$	$t(n_1 + n_2 - 2)$	$ T \geq t_{\frac{\alpha}{2}}(n_1 + n_2 - 2)$ $T \geq t_\alpha(n_1 + n_2 - 2)$ $T \leq -t_\alpha(n_1 + n_2 - 2)$
$\sigma_1^2 = \sigma_2^2$ (μ_1, μ_2 known)	$\sigma_1^2 = \sigma_2^2$ $\sigma_1^2 \leq \sigma_2^2$ $\sigma_1^2 \geq \sigma_2^2$	$\sigma_1^2 \neq \sigma_2^2$ $\sigma_1^2 > \sigma_2^2$ $\sigma_1^2 < \sigma_2^2$	$F = \frac{n_2 \sum_{i=1}^{n_1} (X_i - \mu_1)^2}{n_1 \sum_{j=1}^{n_2} (Y_j - \mu_2)^2}$	$F(n_1, n_2)$	$F \leq F_{1-\frac{\alpha}{2}}(n_1, n_2)$ or $F \geq F_{\frac{\alpha}{2}}(n_1, n_2)$ $F \geq F_\alpha(n_1, n_2)$ $F \leq F_{1-\alpha}(n_1, n_2)$
$\sigma_1^2 = \sigma_2^2$ (μ_1, μ_2 unknown)	$\sigma_1^2 = \sigma_2^2$ $\sigma_1^2 \leq \sigma_2^2$ $\sigma_1^2 \geq \sigma_2^2$	$\sigma_1^2 \neq \sigma_2^2$ $\sigma_1^2 > \sigma_2^2$ $\sigma_1^2 < \sigma_2^2$	$F = \frac{S_1^2}{S_2^2}$	$F(n_1 - 1, n_2 - 2)$	$F \leq F_{1-\frac{\alpha}{2}}(n_1 - 1, n_2 - 1)$ or $F \geq F_{\frac{\alpha}{2}}(n_1 - 1, n_2 - 1)$ $F \geq F_\alpha(n_1 - 1, n_2 - 1)$ $F \leq F_{1-\alpha}(n_1 - 1, n_2 - 1)$